Представления регулярных языков. Критерий регулярности

Теория формальных языков $2022 \ z$.



Недетерминированные КА

Определение

Недетерминированный конечный автомат (NFA) — это пятёрка $\mathscr{A} = \langle Q, \Sigma, q_0, F, \delta \rangle$, где:

- Q множество состояний;
- Σ алфавит терминалов;
- δ множество правил перехода вида $\langle q_i, (\alpha_i | \epsilon), M_i \rangle$, где $q_i \in Q$, $\alpha_i \in \Sigma$, $M_i \in \mathbb{Z}^Q$;
- $q_0 \in Q$ начальное состояние;
- F ⊆ Q множество конечных состояний.

Сокращаем: $\langle q_1, \alpha, q_2 \rangle \in \delta \Leftrightarrow \langle q_1, \alpha, M \rangle \in \delta \& q_2 \in M$.



Недетерминированные КА

Определение

Недетерминированный конечный автомат (NFA) — это пятёрка $\mathscr{A}=\langle Q, \Sigma, \mathfrak{q}_0, \mathsf{F}, \delta \rangle.$

- $\begin{array}{c} \bullet \ q \xrightarrow{\epsilon} q' \Leftrightarrow (q=q') \vee \exists p_1, \ldots, p_k (\langle q, \epsilon, p_1 \rangle \in \delta \ \& \\ \langle p_k, \epsilon, q' \rangle \in \delta \ \& \ \forall i, 1 \leqslant i < k \langle p_i, \epsilon, p_{i+1} \rangle \in \delta). \end{array}$
- $\begin{array}{l} \bullet \ q \overset{\alpha_1 \dots \alpha_k}{\longrightarrow} \ q' \Leftrightarrow \exists p_1, \dots, p_{k-1} (q \xrightarrow{\alpha_1} p_1 \ \& \ p_{k-1} \xrightarrow{\alpha_k} q' \ \& \\ \forall i, 1 \leqslant i < k 1 (p_i \xrightarrow{\alpha_{i+1}} p_{i+1})). \end{array}$



Недетерминированные КА

Определение

Недетерминированный конечный автомат (NFA) — это пятёрка $\mathscr{A} = \langle Q, \Sigma, q_0, F, \delta \rangle$.


- $\begin{array}{c} \bullet \ q \xrightarrow{\epsilon} q' \Leftrightarrow (q=q') \vee \exists p_1, \ldots, p_k (\langle q, \epsilon, p_1 \rangle \in \delta \ \& \\ \langle p_k, \epsilon, q' \rangle \in \delta \ \& \ \forall i, 1 \leqslant i < k \langle p_i, \epsilon, p_{i+1} \rangle \in \delta). \end{array}$
- $\begin{array}{c} \bullet \ q \overset{\alpha_1 \dots \alpha_k}{\longrightarrow} \ q' \Leftrightarrow \exists p_1, \dots, p_{k-1} (q \overset{\alpha_1}{\longrightarrow} p_1 \ \& \ p_{k-1} \overset{\alpha_k}{\longrightarrow} q' \ \& \\ \forall i, 1 \leqslant i < k 1 (p_i \overset{\alpha_{i+1}}{\longrightarrow} p_{i+1})). \end{array}$

Определение

Язык L, распознаваемый НКА \mathscr{A} — это множество слов $\{w \mid \exists q \in F(q_0 \xrightarrow{w} q)\}.$



- A





Детерминированный КА

Определение

Детерминированный конечный автомат (DFA) — это пятёрка $\mathscr{A} = \langle Q, \Sigma, q_0, F, \delta \rangle$, где:

- Q множество состояний;
- Σ алфавит терминалов;
- δ множество правил перехода вида $\langle q_i, \alpha_i, q_j \rangle$, где $q_i, q_j \in Q, \alpha_i \in \Sigma$, причём $\forall q_i, \alpha_i \exists q_j (\langle q_i, \alpha_i, q_j \rangle \in \delta \& \forall q_k (\langle q_i, \alpha_i, q_k \rangle \in \delta \Rightarrow q_k = q_j));$
- $q_0 \in Q$ начальное состояние;
- $F \subseteq Q$ множество конечных состояний.

 ϵ -переходов нет \Rightarrow q $\stackrel{\alpha}{\longrightarrow}$ q' \Leftrightarrow \langle q, α , q' \rangle \in δ .



Детерминированный КА

Определение

Детерминированный конечный автомат (DFA) — это пятёрка $\mathscr{A} = \langle Q, \Sigma, q_0, F, \delta \rangle$, где:

- Q множество состояний;
- Σ алфавит терминалов;
- δ множество правил перехода вида $\langle q_i, \alpha_i, q_j \rangle$, где $q_i, q_j \in Q, \alpha_i \in \Sigma$, причём $\forall q_i, \alpha_i \exists q_j (\langle q_i, \alpha_i, q_j \rangle \in \delta \& \forall q_k (\langle q_i, \alpha_i, q_k \rangle \in \delta \Rightarrow q_k = q_j));$
- $q_0 \in Q$ начальное состояние;
- F ⊂ Q множество конечных состояний.

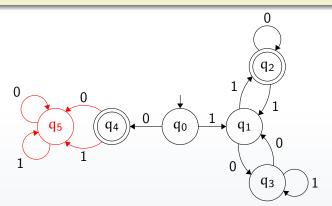
$$\epsilon$$
-переходов нет \Rightarrow q $\stackrel{\alpha}{\longrightarrow}$ q' \Leftrightarrow \langle q, α , q' \rangle \in δ .

Язык L, распознаваемый \mathscr{A} — это множество слов $\{w \mid \exists q \in F(q_0 \xrightarrow{w} q)\}.$



Sink/trap state (состояние–ловушка)

«Ловушка» — не конечное состояние с переходами лишь в себя. Нужны для корректного задания DFA, но иногда по умолчанию не описываются.





Детерминизация NFA


Ot $\mathscr{A} \kappa \mathsf{D}(\mathscr{A})$

Состояния DFA D(\mathscr{A}) — это состояния $\mathfrak{m}_i \in 2^Q$, где Q — состояния NFA \mathscr{A} .

- $m_0 = \{q_i \mid q_0 \stackrel{\epsilon}{\longrightarrow} q_i\};$
- $\bullet \ m_i \in F_D \Leftrightarrow \exists q_i, q_j \{q_i \in m_i \ \& \ q_j \in F(\mathscr{A}) \ \& \ q_i \stackrel{\epsilon}{\longrightarrow} q_j \};$
- $\bullet \ \langle m, \alpha, m' \rangle \in \delta_D \Leftrightarrow m' = \{q_i \, | \, \exists q_j \in m(q_j \stackrel{\alpha}{\longrightarrow} q_i)\}.$



Пример детерминизации




$$\bullet \ \{q_0\} \stackrel{\alpha}{\longrightarrow} \{q_1, q_8\}, \{q_0\} \stackrel{b}{\longrightarrow} \{q_4, q_9\};$$

- $$\begin{split} \bullet & \left\{q_1, q_8\right\} \stackrel{\alpha}{\longrightarrow} \left\{q_1, q_2\right\}, \\ & \left\{q_1, q_8\right\} \stackrel{b}{\longrightarrow} \left\{q_3\right\}; \left\{q_1, q_8\right\} \sim \mathfrak{m}_1. \end{split}$$
- $$\begin{split} \bullet \ \ \{q_1,\,q_2\} & \stackrel{\alpha}{\longrightarrow} \{q_1,\,q_2\}, \\ \{q_1,\,q_2\} & \stackrel{b}{\longrightarrow} \{q_3\}; \{q_1,\,q_2\} \sim m_2. \end{split}$$
- $\bullet \ \{q_3\} \stackrel{\alpha}{\longrightarrow} \{q_1, q_2\}, \{q_3\} \stackrel{b}{\longrightarrow} \{q_3\};$
- $\begin{array}{c} \bullet \ \, \{q_4,\,q_9\} \stackrel{b}{\longrightarrow} \{q_4,\,q_6\}, \\ \{q_4,\,q_9\} \stackrel{a}{\longrightarrow} \{q_5\}; \{q_4,\,q_9\} \sim m_3; \end{array}$
- $\{q_4, q_6\} \xrightarrow{b} \{q_4, q_6\},\$ $\{q_4, q_6\} \xrightarrow{a} \{q_5\}; \{q_4, q_6\} \sim m_4.$
- $\bullet \{q_5\} \xrightarrow{b} \{q_4, q_6\}, \{q_5\} \xrightarrow{a} \{q_5\}.$



Пример детерминизации



$$\bullet \ \{q_0\} \xrightarrow{\alpha} \{q_1, q_8\}, \{q_0\} \xrightarrow{b} \{q_4, q_9\};$$

- $$\begin{split} \bullet & \left\{q_1, q_8\right\} \stackrel{\alpha}{\longrightarrow} \left\{q_1, q_2\right\}, \\ & \left\{q_1, q_8\right\} \stackrel{b}{\longrightarrow} \left\{q_3\right\}; \left\{q_1, q_8\right\} \sim \mathfrak{m}_1. \end{split}$$
- $$\begin{split} \bullet \ \, \{q_1,\,q_2\} & \stackrel{\alpha}{\longrightarrow} \{q_1,\,q_2\}, \\ \{q_1,\,q_2\} & \stackrel{b}{\longrightarrow} \{q_3\}; \{q_1,\,q_2\} \sim m_2. \end{split}$$
- $\bullet \ \{q_3\} \stackrel{\alpha}{\longrightarrow} \{q_1, q_2\}, \{q_3\} \stackrel{b}{\longrightarrow} \{q_3\};$
- $\begin{array}{c} \bullet \ \, \{q_4,\,q_9\} \stackrel{b}{\longrightarrow} \{q_4,\,q_6\}, \\ \{q_4,\,q_9\} \stackrel{\alpha}{\longrightarrow} \{q_5\}; \{q_4,\,q_9\} \sim m_3; \end{array}$
- $\{q_4, q_6\} \xrightarrow{b} \{q_4, q_6\},\$ $\{q_4, q_6\} \xrightarrow{a} \{q_5\}; \{q_4, q_6\} \sim m_4.$
- $\bullet \ \{q_5\} \xrightarrow{b} \{q_4, q_6\}, \{q_5\} \xrightarrow{a} \{q_5\}.$



Гомоморфизм над свободной полугруппой (множеством слов) полностью определяется значениями на буквах, поскольку по определению $h(a_1 \circ a_2 \circ \cdots \circ a_n) = h(a_1) \circ h(a_2) \circ \cdots \circ h(a_n)$. Здесь \circ —конкатенация.

Утверждение

Пусть L — регулярный язык над Σ. Тогда регулярны:

- язык $\Sigma^* \setminus L$;
- для любого гомоморфизма h язык $\{h(w) | w \in L\};$
- \bullet для любого гомоморфизма h язык $\{w \mid h(w) \in L\}$.



Утверждение

Пусть L — регулярный язык над Σ. Тогда регулярны:

- язык $\Sigma^* \setminus L$;
- для любого гомоморфизма h язык $\{h(w) | w \in L\};$
- для любого гомоморфизма h язык $\{w \mid h(w) \in L\}$.

Рассмотрим DFA $\mathscr{A}=\langle Q, \Sigma, q_0, F, \delta \rangle$, распознающий L. Построим $\mathscr{A}'=\langle Q, \Sigma, q_0, Q \setminus F, \delta \rangle$. Тогда $w \notin L \Leftrightarrow w \in L(\mathscr{A}')$.



Утверждение

Пусть L — регулярный язык над Σ. Тогда регулярны:

- язык Σ* \ L;
- для любого гомоморфизма h язык $\{h(w) \, | \, w \in L\};$
- для любого гомоморфизма h язык $\{w \mid h(w) \in L\}$.

Рассмотрим регулярное выражение R такое, что L(R)=L. Заменим в нём все $\alpha_i\in \Sigma$ на $h(\alpha_i)$. Полученное таким образом выражение R' также регулярно, причём L(R')=h(L).



Утверждение

Пусть L — регулярный язык над Σ . Тогда регулярны:

- язык $\Sigma^* \setminus L$;
- для любого гомоморфизма h язык $\{h(w) | w \in L\};$
- для любого гомоморфизма h язык $\{w \mid h(w) \in L\}$.

Рассмотрим DFA $\mathscr{A}=\langle Q, \Sigma, q_0, F, \delta \rangle$, распознающий L. Построим $\mathscr{A}'=\langle Q, \Sigma, q_0, F, \delta' \rangle$ такой, что $\langle q_i, \alpha, q_j \rangle \in \delta' \Leftrightarrow q_i \stackrel{h(\alpha)}{\longrightarrow} q_j$ в исходном автомате \mathscr{A} .



Примеры

Рассмотрим язык $L' = \{a^nb^m \mid n \neq m\}$. Предположим, L' регулярен. Тогда $a^*b^* \setminus L' = \{a^nb^n\}$ также регулярен, а мы знаем, что это не так. \bot



Примеры

Рассмотрим язык $L' = \{a^nb^m \mid n \neq m\}$. Предположим, L' регулярен. Тогда $a^*b^* \setminus L' = \{a^nb^n\}$ также регулярен, а мы знаем, что это не так. \bot

Рассмотрим язык $L^f = \{(abaabb)^n b^n\}.$

Попытка доказать его нерегулярность леммой о накачке породит перебор по накачиваемым строкам $(abaabb)^+$, $(abaabb)^*a$, $(abaabb)^*aba$, $(abaabb)^*aba$, $(abaabb)^*aba$, \dots Рассмотрим гомоморфизм h(a)=abaabb, h(b)=b. $h^{-1}(L^f)=\{a^nb^n\}$, который был бы регулярен, если бы L^f был регулярен. \bot



Эквивалентность слов в DFA

Пусть дан DFA A. Положим

$$w_1 \equiv_{\mathscr{A}} w_2 \Leftrightarrow \exists q_\mathfrak{i} (q_0 \xrightarrow{w_1} q_\mathfrak{i} \& q_0 \xrightarrow{w_2} q_\mathfrak{i}).$$

Если $w_1 \equiv_{\mathscr{A}} w_2$, тогда $\forall z (w_1 z \in \mathsf{L}(\mathscr{A}) \Leftrightarrow w_2 z \in \mathsf{L}(\mathscr{A})).$



Эквивалентность слов в DFA

Пусть дан DFA \mathscr{A} . Положим

$$w_1 \equiv_{\mathscr{A}} w_2 \Leftrightarrow \exists q_i (q_0 \xrightarrow{w_1} q_i \& q_0 \xrightarrow{w_2} q_i).$$

Если $w_1 \equiv_{\mathscr{A}} w_2$, тогда $\forall z (w_1 z \in \mathsf{L}(\mathscr{A}) \Leftrightarrow w_2 z \in \mathsf{L}(\mathscr{A}))$. Рассмотрим более общее отношение. Положим

 $w_1 \equiv_L w_2 \Leftrightarrow \forall z (w_1 z \in L \Leftrightarrow w_2 z \in L)$. Это отношение разбивает L на классы эквивалентности.

Теорема Майхилла-Нероуда

Язык L регулярен тогда и только тогда, когда множество его классов эквивалентности по $\equiv_{\mathbb{I}}$ конечно.



Критерий регулярности языка

Теорема Майхилла-Нероуда

Язык L регулярен тогда и только тогда, когда множество классов эквивалентности по $\equiv_{\mathbb{I}}$ конечно.



Критерий регулярности языка

Теорема Майхилла-Нероуда

Язык L регулярен тогда и только тогда, когда множество классов эквивалентности по $\equiv_{\rm L}$ конечно.

 \Rightarrow : Пусть L регулярен. Тогда он порождается некоторым DFA $\mathscr A$ с конечным числом состояний N. Значит, множество $\{q_i \mid q_0 \stackrel{w}{\longrightarrow} q_i\}$ конечно, а для каждых двух w_1 , w_2 таких, что $q_0 \stackrel{w_1}{\longrightarrow} q_i$ и $q_0 \stackrel{w_2}{\longrightarrow} q_i$, выполняется $w_1 \equiv_L w_2$.



Критерий регулярности языка

Теорема Майхилла-Нероуда

Язык L регулярен тогда и только тогда, когда множество классов эквивалентности по \equiv_{L} конечно.

 \Leftarrow : Пусть все слова в Σ^* принадлежат N классам эквивалентности A_1, \ldots, A_n по \equiv_L . Построим по ним DFA \mathscr{A} , распознающий L. Классы A_i объявим состояниями.

- Начальным состоянием объявим класс эквивалентности A_0 такой, что $\varepsilon \in A_0$.
- Конечными объявим такие A_i , что $\forall w \in A_i (w \in L)$.
- Если $w \in A_i$, $w \alpha_k \in A_j$, тогда добавляем в δ правило $\langle A_i, \alpha_k, A_j \rangle$. $\forall w_1, w_2 \in A_i, w_1 \alpha_k$ и $w_2 \alpha_k$ всегда принадлежат одному и тому же A_j .




Минимизация DFA

- **П**остроим таблицу всех двухэлементных множеств $\{q_i, q_i\}, q_i, q_i ∈ Q.$
- **②** Пометим все множества $\{q_i, q_j\}$ такие, что одно из q_i, q_i из F, а второе нет.
- Пометим все множества $\{q_i, q_j\}$ такие, что $\exists \alpha(q_i \xrightarrow{\alpha} q_1' \& q_j \xrightarrow{\alpha} q_2' \& \{q_1', q_2'\}$ помеченная пара).
- Продолжаем шаг 3, пока не будет появляться новых помеченных пар.


Пары, оставшиеся непомеченными, можно объединить.






m_1						
m_2						
q_3						
m_3						
m_4						
q_5						
	q_0	\mathfrak{m}_1	\mathfrak{m}_2	q ₃	m_3	m_4






$\overline{m_1}$						
m_2						
q ₃	√	√	√			
m_3				√		
m_4				√		
q_5	√	√	√		√	√
	q ₀	m_1	m_2	q ₃	m_3	m ₄





\mathfrak{m}_1						
m_2						
q ₃	√	√	√			
m_3				√		
m_4				√		
q_5	√	√	√		√	√
	q ₀	\mathfrak{m}_1	\mathfrak{m}_2	q ₃	m_3	m ₄
_						<u> </u>






\mathfrak{m}_1	\checkmark					
\mathfrak{m}_2	\checkmark					
q ₃	√	√	√			
m_3				√		
m_4				√		
q ₅	√	√	√		√	√
	q ₀	m_1	m_2	q ₃	m_3	m ₄

$$q_0 \xrightarrow{\alpha} m_1, m_4 \xrightarrow{\alpha} q_5$$
 $m_1 \xrightarrow{\alpha} m_2, m_4 \xrightarrow{\alpha} q_5$

$$m_1 \xrightarrow{\alpha} m_2, m_3 \xrightarrow{\alpha} q$$

 $m_2 \xrightarrow{\alpha} m_2, m_4 \xrightarrow{\alpha} q$






m_1	√					
m_2	√					
	√	√	√			
m_3	√	√	√	√		
m_4	√	√	√	√		
q_5	√	√	√		√	√
	q_0	m_1	m_2	q ₃	m_3	m_4

$$\{m_3, m_4\} \xrightarrow{\alpha} q_5 \qquad \{m_3, m_4\} \xrightarrow{b} m_4$$


$$q_3 \xrightarrow{\alpha} m_2, q_5 \xrightarrow{\alpha} m_4$$





m_2						
	√					
q ₃	\checkmark	√	√			
m ₃	\checkmark	√	√	√		
m ₄	√	√	√	√		
q_5	√	√	√	√	√	√
	q_0	\mathfrak{m}_1	\mathfrak{m}_2	q ₃	m_3	m ₄

Можно объединить состояния m_1 и m_2 и состояния m_3 и m_4 .



m_1	√					
m_2	√					
q ₃	√	√	√			
m ₃	√	√	√	√		
m ₄	√	√	√	√		
$\overline{q_5}$	√	√	√	√	√	√
	q ₀	\mathfrak{m}_1	\mathfrak{m}_2	q ₃	m_3	m_4

Меньше чем пятью состояниями не обойтись. Рассмотрим слова ϵ , α , b, αb , $b \alpha$. Каждые два из них различаются по \equiv_L при выборе одного из трёх z: ϵ , α или b.



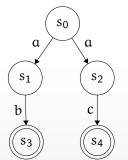
Бисимуляция

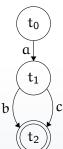
Скажем, что состояния s_1 , s_2 системы переходов \mathscr{A} находятся в отношении бисимуляции ($s_1 \sim s_2$), если выполняются условия:

•
$$\forall t_1, \alpha(s_1 \xrightarrow{\alpha} t_1 \Rightarrow \exists t_2(s_2 \xrightarrow{\alpha} t_2 \& t_1 \sim t_2));$$

$$\bullet \ \, \forall t_2 \text{, } \alpha(s_2 \stackrel{\alpha}{\longrightarrow} t_2 \Rightarrow \exists t_1(s_1 \stackrel{\alpha}{\longrightarrow} t_1 \And t_1 \sim t_2)).$$

Бисимуляция — более сильное свойство, чем эквивалентность!







Связь М.- N. и производных

Пусть $w^{-1}U$ — это производная U по w, т.е. $\{v, | wv \in U\}$. Тогда выполнено $x \equiv_U y \Leftrightarrow x^{-1}U = y^{-1}U$.

- Количество производных (как языков) регулярного языка конечно.
- Конструкция Брзозовки порождает минимальный DFA.



Связь М.– N. и производных

Пусть $w^{-1}U$ — это производная U по w, т.е. $\{v, | wv \in U\}$. Тогда выполнено $x \equiv_U y \Leftrightarrow x^{-1}U = y^{-1}U$.

- Количество производных (как языков) регулярного языка конечно.
- Конструкция Брзозовки порождает минимальный DFA.

Но проблема с правилами переписывания (АСІ):

- $(w_1|w_2)|w_3=w_1|(w_2|w_3)$
- $w_1 | w_2 = w_2 | w_1$
- $\bullet w | w = w$



Применение теоремы М.- N.

Задача

Дан язык L. Показать, что он не регулярен, пользуясь теоремой Майхилла–Нероуда.

Стандартный подход

- Подобрать бесконечную последовательность префиксов w_1, \ldots, w_n, \ldots
- **⑤** Доказать, что в таблице конкатенаций все строки различны (значит, $\forall i, j \exists k(w_i z_k \in L \& w_i z_k \notin L)$).



Диагональная конструкция

Рассмотрим язык $L = \{a^nb^n\}$. Положим $w_i = a^i, z_i = b^i$. Тогда таблица конкатенаций w_i, z_j будет выглядеть следующим образом. Здесь + — это то же, что « \in L», — читаем как « \notin L».

	$ z_1 = b $	$z_2 = b^2$	$z_3 = b^3$	$\dots z_n = b^n \dots$
$w_1 = a$	+	_	_	_
$w_2 = a^2$	_	+	_	_
$w_3 = a^3$	-	_	+	_
$w^n = a^n$	-	_	_	+



Доказательство минимальности

Так же можно обосновывать минимальность DFA. Рассмотрим минимальный автомат из примера выше. Его язык — слова в $\{a, b\}^*$, начинающиеся и заканчивающиеся одной и той же буквой. Построим таблицу классов эквивалентности по $w_i \in \{\varepsilon, a, b, ab, ba\}$.

	ε	a	b
ε	+	+	+
a	+	+	_
b	+	_	+
ab	_	+	_
ba	_	_	+
ba	—	_	+

В этой таблице все строчки различны, значит, выбранные w_i действительно лежат в различных классах эквивалентности, и DFA, распознающий язык L, не может иметь меньше пяти состояний.

При доказательстве минимальности DFA достаточно подобрать $[\log_2 n] + 1$ различающих суффиксов z_i , где n — число состояний автомата.



О порождении новых алгоритмов

Пусть \mathscr{A} — NFA. Тогда $\det(\text{reverse}(\det(\text{reverse}(\mathscr{A}))))$ — минимальный DFA, эквивалентный \mathscr{A} .


Многие алгоритмы для порождения малых (не минимальных) NFA являются комбинациями нескольких базовых операций.

- Обращение автомата
- Детерминизация
- Удаление ε-правил
- Минимизация
- Разметка



Автомат Томпсона

- Единственное начальное состояние
- Единственное конечное состояние
- Не больше двух переходов из каждого состояния





Несколько конструкций

- Автомат Глушкова: rmeps(Th(R));
- Автомат Антимирова: rmeps(deannote(minimize(rmeps(annote_eps(Th(R)))));
- Автомат Илия-Ю: deannote(minimize(rmeps(annote(Th(R))))).