### Контекстно-свободные грамматики. Деревья разбора. Нормальная форма Хомского. Первая лемма о накачке

Теория формальных языков  $2022 \ z$ .



### Ограничения регулярных грамматик

- (синтаксический моноид) Слова лишь конечно различимы относительно правил переписывания
- (префиксные грамматики) Доступ лишь к началу (концу) слова

Что будет, если снять эти условия?



### Ограничения регулярных грамматик

- (синтаксический моноид) Слова лишь конечно различимы относительно правил переписывания
- (префиксные грамматики) Доступ лишь к началу (концу) слова

Что будет, если снять эти условия?

Структура вывода — дерево, а не последовательность.





### Ограничения регулярных грамматик

- (синтаксический моноид) Слова лишь конечно различимы относительно правил переписывания
- (префиксные грамматики) Доступ лишь к началу (концу) слова

Что будет, если снять эти условия?

Структура вывода — дерево, а не последовательность.







## Контекстно-свободные грамматики

### Определение

Контекстно-свободная грамматика (CFG) — это грамматика  $\langle \Sigma, N, P, S \rangle$ , где правила переписывания Р имеют вид  $A \to \alpha$ ,  $A \in N$ ,  $\alpha \in (\Sigma \cup N)^*$ .

- Нетерминалы переписываются независимо друг от друга (можно понимать их как нульместные функции).
- Вывод в грамматике (разбор слова) не линеен.



### Контекстно-свободные грамматики

### Определение

Контекстно-свободная грамматика (CFG) — это грамматика  $(\Sigma, N, P, S)$ , где правила переписывания P имеют вид  $A \to \alpha$ ,  $A \in \mathbb{N}$ ,  $\alpha \in (\Sigma \cup \mathbb{N})^*$ .

- Нетерминалы переписываются независимо друг от друга (можно понимать их как нульместные функции).
- Вывод в грамматике (разбор слова) не линеен.

### **Грамматика** G<sub>1</sub>

$$S \rightarrow SS$$

$$\begin{array}{ccc} S & \rightarrow & (S) \\ S & \rightarrow & \epsilon \end{array}$$

$$S \rightarrow \epsilon$$

$$S \rightarrow B \qquad R \rightarrow )$$

$$B \rightarrow (RB R \rightarrow (RR))$$

$$B \rightarrow \epsilon$$




### Неоднозначность разбора

### Грамматика G<sub>1</sub> для языка Дика

 $S \ \to \ S\,S$ 

 $S \ \rightarrow \ (S)$ 

 $S \rightarrow \varepsilon$ 





## Левосторонний разбор

Шаг левостороннего разбора с.ф.  $\alpha_1 A \alpha_2$ , где  $\alpha_1 \in \Sigma^*$ ,  $A \in \mathbb{N}$ , — замена выделенного вхождения A на правую часть  $A \to \beta$ . Левосторонний разбор S — разбор, каждый шаг которого левосторонний.




### Левосторонний разбор

Шаг левостороннего разбора с.ф.  $\alpha_1 A \alpha_2$ , где  $\alpha_1 \in \Sigma^*$ ,  $A \in \mathbb{N}$ , — замена выделенного вхождения A на правую часть  $A \to \beta$ . Левосторонний разбор S — разбор, каждый шаг которого левосторонний.

 $\rightarrow$  (S)

Левосторонний разбор не обязательно единственный, см. ниже.





## Левосторонний разбор

Шаг левостороннего разбора с.ф.  $\alpha_1 A \alpha_2$ , где  $\alpha_1 \in \Sigma^*$ ,  $A \in \mathbb{N}$ , — замена выделенного вхождения A на правую часть  $A \to \beta$ . Левосторонний разбор S — разбор, каждый шаг которого левосторонний.


### Утверждение

Между деревьями разбора слов  $w \in L(G)$  и левосторонними разборами w есть взаимно-однозначное соответствие.



## (Не)однозначность грамматик

| Грамматика G <sub>2</sub> для языка Дика |               |     |   |               |     |
|--|---------------|-----|---|---------------|-----|
| S  | $\rightarrow$ | В   | R | $\rightarrow$ | )   |
| В  | $\rightarrow$ | (RB | R | $\rightarrow$ | (RR |
| В  | $\rightarrow$ | ε   |   |               |     |



Грамматика  $G_2$  однозначна — для всех  $w \in L(G_2)$  существует единственный левосторонний разбор w. Достаточно заглянуть на 1 символ после разобранной позиции.



## Другие проблемы контекстно- свободного разбора слов

- $\varepsilon$ -правила (правила вида  $A \to \varepsilon$ );
- «є-переходы», или цепные правила (правила вида  $A \rightarrow B$ ).



## Устранение ε-правил



### Устранение ε-правил

- Объявляем Nullable  $= \emptyset;$
- $\forall A \in \mathsf{N},$  если  $A \to \varepsilon$ , тогда Nullable = Nullable  $\cup \{A\};$
- Пока Nullable меняется:
  - для всех  $A \in \mathbb{N}$ , если  $A \to B_1 \dots B_n$ ,  $B_i \in \text{Nullable}$   $\Rightarrow \text{Nullable} = \text{Nullable} \cup \{A\}.$
- Итоговое множество Nullable множество всех коллапсирующих нетерминалов.



### Устранение $\varepsilon$ -правил

- Если  $\varepsilon \in L(G)$ , тогда добавляем новый стартовый символ  $S_0$  и правила  $S_0 \to \varepsilon, S_0 \to S$ .
- Стираем все правила  $B_i \to \epsilon$ , кроме  $S_0 \to \epsilon$ .
- Для всех правил  $A \to \alpha_1 B_i \alpha_2$ , где  $B_i \in$  Nullable, добавляем правила  $A \to \alpha_1 \alpha_2$ .



### Устранение ε-правил

- Если  $\varepsilon \in L(G)$ , тогда добавляем новый стартовый символ  $S_0$  и правила  $S_0 \to \varepsilon, S_0 \to S$ .
- Стираем все правила  $B_i \to \epsilon$ , кроме  $S_0 \to \epsilon$ .
- Для всех правил  $A \to \alpha_1 B_i \alpha_2$ , где  $B_i \in \text{Nullable}$ , добавляем правила  $A \to \alpha_1 \alpha_2$ . И получаем новые  $\epsilon$ -правила! Порядок преобразований существенен.



### **Устранение** ε-правил

- Если  $\varepsilon \in L(G)$ , тогда добавляем новый стартовый символ  $S_0$  и правила  $S_0 \to \varepsilon, S_0 \to S$ .
- Для всех правил  $A \to \alpha_1 B_i \alpha_2 \ (|\alpha_1 \alpha_2| \geqslant 1)$ , где  $B_i \in \text{Nullable}$ , добавляем правила  $A \to \alpha_1 \alpha_2$ .
- Стираем все правила  $B_i \to \epsilon$ , кроме  $S_0 \to \epsilon$ .



### Уничтожение цепных правил

- Строим транзитивное замыкание  $A \to_c^* B$  отношения  $A \to_c B : A \to B \in P$ .
- ullet  $\forall A, B: A 
  ightarrow_c$  B, строим множество правил  $A 
  ightarrow \varphi_i$ , для которых  $\exists C, \varphi_i(C 
  ightarrow \varphi_i \in P \& (B 
  ightarrow_c^* C \lor C = B) \& (|\varphi_i| > 1 \lor \varphi_i = \epsilon \lor (\varphi_i = \alpha \& \alpha \in \Sigma))).$
- Удаляем все правила  $A \to B$ .



### Нормальная форма Хомского

### Определение

Грамматика G находится в нормальной форме Хомского (CNF)  $\Leftrightarrow$  все её правила имеют вид либо  $A \to a$ , либо  $A \to BC$ , либо  $S \to \varepsilon$ , причём S не входит в правую часть никакого правила из G.



### Нормальная форма Хомского

### Определение

Грамматика G находится в нормальной форме Хомского (CNF)  $\Leftrightarrow$  все её правила имеют вид либо  $A \to a$ , либо  $A \to BC$ , либо  $S \to \varepsilon$ , причём S не входит в правую часть никакого правила из G.

- Устраняем ε-правила.
- Устраняем цепные правила.
- $\forall \alpha \in \Sigma$  таких, что  $\alpha$  входит в правую часть правила, отличную от  $\alpha$ , заводим нетерминал—охранник  $G_{\alpha}$ , строим правило  $G_{\alpha} \to \alpha$ , и во всех правых частях, кроме совпадающих  $\alpha$ , заменяем  $\alpha$  на  $G_{\alpha}$ .
- $\forall A \to B_1 \dots B_n$ , n > 2, вводим новый нетерминал  $B_{1f}$  и заменяем  $A \to B_1 \dots B_n$  на два правила  $A \to B_1 B_{1f}$ ,  $B_{1f} \to B_2 \dots B_n$  (рекурсивно).



## Смысл нормальной формы Хомского

- Неукорачивающие применения правил
- Нет пустых переходов правила либо финальные, либо удлиняющие
- Контролируемый рост длины сентенциальной формы от количества шагов разбора

Перевод грамматики в CNF позволяет легче анализировать свойства её языка и проводить разбор слов.



### Недостижимость и зацикливание

- ullet Стартовый нетерминал  $S\in N$  достижим.
- Нетерминал  $A \in \mathbb{N}$  достижим, если существует правило  $B \to \alpha$  такое, что  $|\alpha|_A \geqslant 1$  и B достижим.

12/22



## Недостижимость и зацикливание

- ullet Стартовый нетерминал  $S\in N$  достижим.
- Нетерминал  $A \in \mathbb{N}$  достижим, если существует правило  $B \to \alpha$  такое, что  $|\alpha|_A \geqslant 1$  и B достижим.
- Если существует правило  $A \to w, w \in \Sigma^*, A$  порождающий.
- Если  $A \to \alpha$  и  $\forall B_\mathfrak{i}(|\alpha|_{B_\mathfrak{i}} \geqslant 1 \Rightarrow B_\mathfrak{i}$  порождающий), то A порождающий.
- Удаляем из G все правила, в левых или правых частях которых стоят непорождающие нетерминалы.
- ② Удаляем из G все правила, в левых или правых частях которых стоят недостижимые нетерминалы.

12 / 22



# Проверка корректности рекурсивных алгоритмов

 Завершаемость — фундированность — искомое множество М нетерминалов не может уменьшаться, и количество нетерминалов грамматики конечно.



# Проверка корректности рекурсивных алгоритмов

- Завершаемость фундированность искомое множество М нетерминалов не может уменьшаться, и количество нетерминалов грамматики конечно.
- Корректность способ доказательства «minimal bad sequence» — пусть существуют элементы  $k_i \in M$ , которые не находятся рекурсивным алгоритмом. Выберем тот из них, до которого минимальный путь из S (варианты — из которого минимальный путь до  $\Sigma^*$ ; до ε). Покажем, что есть ещё какой-то с путём вывода ещё короче.



### **Н.Ф.** Хомского и префиксные грамматики

При линеаризации правил, поведение КС-грамматики G в Н.Ф. Хомского в точности описывается алфавитной префиксной грамматикой на нетерминалах.

- Переведём АПГ в регулярную грамматику по методу, описанному в предыдущей лекции.
- У этой грамматики есть длина накачки, т.е. всякое достаточно длинное слово имеет вид  $w_1(w_2)^n w_3$ , причём  $w_1w_3$  также входит в язык сентенциальных форм G.

Поскольку G — КС-грамматика, то  $w_1 \longrightarrow \alpha_1, w_3 \longrightarrow \alpha_3$ , каждое из  $w_2 \longrightarrow \alpha_2$ .

Но ещё есть шаг порождения  $w_2$ , также выбрасывающий последовательность терминалов.



## Лемма о накачке КС-языков

### Лемма о накачке (разрастании)

Пусть G — KC-грамматика в форме Хомского. Тогда существует  $p \in \mathbb{N}$  такое, что любое слово  $w \in L(G)$  длины не меньше p имеет представление вида  $x_1y_1zy_2x_2$ , где  $|y_1y_2| \geqslant 1, |y_1zy_2| \leqslant p$ , и все слова вида  $x_1y_1^kzy_2^kx_2$  также принадлежат L(G).




## Лемма о накачке КС-языков

Пусть в н.ф. Хомского G п нетерминалов. Возьмём  $p=2^n$ . Его вывод будет иметь минимум высоту  $n+1\Rightarrow$  в нём будет существовать путь, содержащий два одинаковых нетерминала A.



### Лемма о накачке КС-языков

Пусть в н.ф. Хомского G п нетерминалов. Возьмём  $p=2^n$ . Его вывод будет иметь минимум высоту  $n+1\Rightarrow$  в нём будет существовать путь, содержащий два одинаковых нетерминала A.



Выберем самые нижние два одинаковых нетерминала  $\Rightarrow$  высота поддерева от первого из них не больше  $n+1 \Rightarrow$  длина выводимого слова  $y_1zy_2 \leqslant 2^n$  (т.е.  $\leqslant p$ ).



## Пример применения

### Парсинг в Python

Проанализировать язык

$$\{a^nz_1a^nz_2a^n|n\geqslant 1, |z_i|_a=0, |z_i|\geqslant 1\}.$$



### Пример применения

### Парсинг в Python

Проанализировать язык  $\{\alpha^n z_1 \alpha^n z_2 \alpha^n | n \geqslant 1, |z_i|_{\alpha} = 0, |z_i| \geqslant 1\}.$ 

Пусть длина накачки есть p. Рассмотрим слово  $a^pba^pba^p$ . Заметим, что если  $y_1zy_2=a^iba^j$  (где i и j могут быть равны 0), тогда  $|y_1y_2|_b=0$ . Действительно, иначе нулевая накачка породит слово  $a^mba^p$ , которое не принадлежит языку.

Значит,  $y_1=a^j, y_2=a^i$ . Однако слова  $a^{p+i+j}ba^pba^p,$   $a^pba^{p+i+j}ba^p, a^pba^{p+i+j}, a^{p+j}ba^{p+i}ba^p,$   $a^pba^{p+i}ba^{p+i}$  ни одно не принадлежат требуемому языку  $\Rightarrow$  он не контекстно-свободен.



## Теоретико-игровая интерпретация

Достаточное условие непринадлежности языка L к КС по лемме о накачке:  $\forall p \exists w \in L(|w| > p \& \forall x_i, y_i, z(w = x_1y_1zy_2x_2 \& |y_1zy_2|$ 

В пренексной форме этого условия кванторы образуют последовательность:  $\forall\exists\forall\exists$ . Эта последовательность задаёт правила игры, где каждый квантор  $\exists$  — ход протагониста, квантор  $\forall$  — ход антагониста. Ходы антагониста назначают неопределённые параметры. Ходы протагониста дают выбор известной вам структуры, зависящей от ходов антагониста. В случае леммы о накачке это выглядит так.

- Антагонист выбирает длину накачки р.
- Зная р, протагонист выбирает w.
- Антагонист выбирает разбиение w на пять подстрок.
- Возможно, в зависимости от этого разбиения, протагонист предъявляет і, для которого накачка не выполняется.



## Теоретико-игровая интерпретация

- Антагонист выбирает длину накачки р.
- Зная р, протагонист выбирает w.
- Антагонист выбирает разбиение w на пять подстрок.
- Возможно, в зависимости от этого разбиения, протагонист предъявляет і, для которого накачка не выполняется.

Иногда такая система анализа свойств, записанных в виде формул с чередующимися кванторами, также называется игрой Элоизы и Абеляра (по буквам, образующим кванторы  $\exists$  и  $\forall$ ).



Пока без доказательства: множество КС-языков замкнуто относительно пересечения с регулярными языками.



### Техника применения

### Сужение перебора

Если в язык L входят подслова произвольной формы из  $\Sigma^+$ , где  $|\Sigma| > 1$ , тогда, скорее всего, потребуется пересечь L с регулярным языком, чтобы облегчить поиск свидетельства о ненакачиваемости. Пример: язык  $\{w_1w_1w_2\,|\,|w_1|_\alpha=|w_2|_\alpha\}$ . Пересечение этого языка с ba\*bba\*bba\* гораздо легче поддаётся анализу, поскольку такие слова разбиваются на подходящие  $w_1$  и  $w_2$  однозначно.

- Начальная буква b вынуждает  $w_1$  содержать ровно две буквы b. Действительно, если  $|w_1|_b=1$ , тогда второе вхождение  $w_1$  должно будет начинаться с  $b^2$ , что противоречит выбору  $w_1$ .
- Последняя буква b навязывает позицию начала  $w_2$ .



### Техника применения

### Работа с отрицанием

Если характеристическая функция L содержит предикат отрицания, связывающий две структуры неопределённого размера, в некоторых случаях это приводит к невозможности применения леммы о накачке. В других можно попробовать воспользоваться приёмом «всё включено». Поскольку мы знаем, что длина накачиваемого фрагмента  $y_1zy_2$  меньше p, то выберем w так, чтобы в нём нашлись всевозможные фрагменты такой длины, удовлетворяющие желательному свойству.



## Техника применения

Покажем, что язык  $L = \{w \mid w \neq a^{n^2} \& w \in \{a,b\}^*\}$  не является КС. Для начала заметим, что слова L содержат произвольные подслова в  $\{a,b\}^*$ , и пересечём L c  $a^*$ . Получим  $L' = \{a^k \mid k \neq n^2\}$  — если он не КС, то исходный язык также не КС.

- Антагонист выбирает р.
- Наша задача подобрать такое k, что  $\forall p' \exists i, m(p' . То есть включить возможность взятия любого такого <math>p'$  в наше значение k как конструктивного элемента для построения квадрата числа.
- ullet Возьмём  $k=(\mathfrak{p}!)^2+1$ . Тогда при любом значении  $\mathfrak{p}'$ , меньшем  $\mathfrak{p}$ , можно взять  $\mathfrak{i}=rac{\mathfrak{p}!}{\mathfrak{p}'}*2$ , и получим  $k+\mathfrak{p}'*\mathfrak{i}=(\mathfrak{p}!+1)^2$ .



## Ещё пример применения

Покажем, что язык  $L = \{ww^R a^n \,|\, |w|_\alpha = n\}$  не является КС. Опять сначала избавимся от произвольных подслов в L и пересечём его с языком  $ba^+b^2a^+ba^+$ . Пересечение с таким языком вынуждает w иметь вид  $ba^ib$ , а весь язык — вид  $L' = \{ba^nbba^nba^n\}$ .

- Абеляр выбирает р. Элоиза строит слово  $ba^pb^2a^pba^p$ . Абеляру предоставляется возможность построить его разбиение на  $x_1y_1zy_2x_2$ .
- Если Абеляр выберет  $|y_1|_a > 0$  &  $|y_1|_b > 0$  (т.е.  $y_1$  содержащим сразу буквы a и b), тогда ненулевая накачка сразу же выведет нас из языка. Аналогично c  $y_2$ .
- Если Абеляр решит накачивать только b (т.е. выберет y<sub>1</sub> либо y<sub>2</sub> равными b или b<sup>2</sup>), тогда любая накачка также будет выводить из языка.



### Ещё пример применения

Покажем, что язык  $L = \{ww^R a^n \mid |w|_a = n\}$  не является КС. Опять сначала избавимся от произвольных подслов в L и пересечём его с языком  $ba^+b^2a^+ba^+$ . Пересечение с таким языком вынуждает w иметь вид  $ba^ib$ , а весь язык — вид  $L' = \{ba^nbba^nba^n\}$ .

- Абеляр выбирает р. Элоиза строит слово  $ba^pb^2a^pba^p$ . Абеляру предоставляется возможность построить его разбиение на  $x_1y_1zy_2x_2$ .
- Остаётся только возможность  $y_1 = a^i$ ,  $y_2 = a^j$ , что позволяет следующие накачки  $y_1$ ,  $y_2$  на расстоянии не больше p:
  - $ba^{p+i*k}b^2a^{p+j*k}ba^p$  можно сохранить свойство палиндрома, но нельзя сохранить корректный подсчёт букв a, последний индекс не меняется.
  - $ba^pb^2a^{p+i*k}ba^{p+j*k}$  теряется свойство палиндрома.
  - $ba^{p+(i+j)*k}b^2a^pba^p$  теряется свойство палиндрома, при накачке только второго подслова  $a^p$  аналогично.
  - $ba^pb^2a^pba^{p+(i+j)*k}$  некорректный подсчёт букв а в w.



Некоторые не КС-языки тоже накачиваются, например,  $\{a^mb^nc^nd^n\,|\,m>0\}\cup\{b^ic^jd^k\}.$ 



Некоторые не КС-языки тоже накачиваются, например,  $\{a^mb^nc^nd^n\,|\,m>0\}\cup\{b^ic^jd^k\}.$ 

Действительно, если слово языка содержит буквы  $\alpha$ , тогда мы можем взять  $y_1y_2=\alpha^i$ . Иначе накачку можно выбрать произвольно.



Некоторые не КС-языки тоже накачиваются, например,  $\{a^mb^nc^nd^n\,|\,m>0\}\cup\{b^ic^jd^k\}.$ 

Действительно, если слово языка содержит буквы  $\alpha$ , тогда мы можем взять  $y_1y_2=\alpha^i$ . Иначе накачку можно выбрать произвольно.

То, что этот язык — не КС, можно понять по тому факту, что его пересечение с регулярным языком  $ab^*c^*d^*$  не контекстно-свободно.



Некоторые не КС-языки тоже накачиваются, например,  $\{a^mb^nc^nd^n\mid m>0\}\cup\{b^ic^jd^k\}.$ 

Действительно, если слово языка содержит буквы  $\alpha$ , тогда мы можем взять  $y_1y_2=\alpha^i$ . Иначе накачку можно выбрать произвольно.

То, что этот язык — не КС, можно понять по тому факту, что его пересечение с регулярным языком  $ab^*c^*d^*$  не контекстно-свободно.

Иногда пересечение с регулярным языком делает язык «излишне накачиваемым»: например, пересекая  $L=\{ww^R\alpha^n\,|\,|w|_\alpha=n\}\,c$   $b\alpha^+b^*\alpha^+b\alpha^+$ , мы даём возможность Абеляру выбрать в качестве  $y_1$  пару букв из центрального блока  $b^*$  (положив  $y_2=\epsilon$ ). Заметим, что слова без этого блока будут иметь вид  $b\alpha^2nb\alpha^n$ — а такие слова тоже можно накачивать, выбрав  $y_1$  из  $\alpha^{2n}$ ,  $y_2$ — из  $\alpha^n$ .